

Было принято решение заменить нейросеть детерминированными синтаксическими шаблонами (паттернами). Идея заключается в том, чтобы для каждого типа отношений задать список характерных фраз (например, «является частью», «состоит из», «обобщает»), которые указывают на наличие связи между понятиями. Затем с помощью DiGr DSL выполнять поиск предложений (или других контекстных окон), где одновременно присутствуют два термина и одна из шаблонных фраз.

Преимущества шаблонного подхода:

- Полная интерпретируемость – результат легко объяснить.
- Не требует размеченных данных для обучения.
- Быстрое внесение изменений – достаточно добавить или удалить шаблон.
- Работает на любом документе, поддерживаемом DiGr.
- Не требует GPU и может выполняться на CPU.
- Легко комбинировать с другими правилами (например, фильтрацией по расстоянию).

Необходимо было:

1. Разработать модуль для извлечения отношений по шаблонам, используя DSL
2. Создать конфигурацию шаблонов для основных типов отношений (generalization, aggregation, composition, association, dependency, input, output, instance, manifest).
3. Обеспечить возможность извлечения терминов из AST документа (например, из сущностей definition).
4. Предоставить простой интерфейс для запуска (CLI-скрипт).
5. Сохранить результаты в структурированном формате (JSON) для дальнейшего использования (загрузка в граф онтологии, Qdrant и т.д.).

При этом старый код `relation_matcher` планировалось либо удалить, либо заархивировать, а основной пайплайн переключить на новый модуль.

Работа велась в рамках проекта DiGr, с использованием уже существующей инфраструктуры:

- DiGr DSL – язык запросов к AST.
- `document_ast` – подсистема построения AST документа.

Был создан новый пакет `relation_extractor` в корне проекта. Он содержит следующие компоненты:

1. `extractor.py` – основной класс `PatternBasedRelationExtractor`

Класс принимает словарь шаблонов (тип отношения → список фраз) и предоставляет два метода:

- `extract(document, terms)` – принимает список терминов (строк) и для каждой пары терминов выполняет DSL-запрос, ища совпадения в пределах одного предложения (CONTEXT sentence LIMIT 1). Возвращает список найденных отношений с контекстом.
- `extract_using_ast_entities(document, entity_name)` – автоматически извлекает термины из заданной сущности AST (например, `definition`), используя их метаданные (например, `metadata.name`) или текст, и затем вызывает `extract`.

Логика запроса:

Для каждой пары (`t1`, `t2`) и каждого типа отношения строится регулярное выражение из всех шаблонных фраз для этого типа (экранирование спецсимволов). Затем выполняется запрос:

```
CONTEXT sentence LIMIT 1
```

```
FOR "{t1}", "{t2}", /{pattern}/
```

```
RETURN window, matches
```

Если находится хотя бы одно окно, извлекается его текст и координаты, и добавляется запись в результат.

2. `templates.yaml` – конфигурация шаблонов

Файл в формате YAML, где ключи – типы отношений (например, `part_of`, `is_a`, `synonym`, `dependency`, `association`, `composition`, `generalization`), а значения – списки строк-шаблонов.